

TP N°01 - TICOD

Notion d'Entropie et Compression de l'Information Par Codage d'Huffman

HALLA Senia - IGE 43 Groupe 02

10 November 2021

1 Mesure de l'information :

1.1 Calcul l'Entropie de la séquence X :

C'est une mesure pour **décrire le désordre** d'un système physique, dans le cas d'un signal on parle alors de la **quantité d'information**, on la calcule avec la formule suivante :

$$H(x) = - \sum_{i=1}^M p_i \cdot \log_m(p_i)$$

| | | | | | | | | | |
|--------------|----------------|----------------|----------------|----------------|----------------|----------------|----------------|-----------------|------|
| Alphabet | A | T | S | U | I | O | N | D | H(X) |
| Probabilités | $\frac{1}{33}$ | $\frac{1}{33}$ | $\frac{2}{33}$ | $\frac{3}{33}$ | $\frac{4}{33}$ | $\frac{5}{33}$ | $\frac{6}{33}$ | $\frac{11}{33}$ | 2.62 |

Résultat de l'Entropie **$H(X) = 2.62$ bits/message**

2 Observation d'une Densité de Probabilité :

2.1 La fonction **Histogram(x,h)**:

Elle donne l'**histogramme de la distribution des symboles** de la source "x", avec le **nombre bins spécifié** par "h" .

2.2 La Sortie du programme pour **L = 1, 2, 3 et 4**:

Voir Figure 1 - Partie 1 Code

2.3 La séquence de symbole :

La nature de la séquence de symbole est une **suite de nombre** qui suivent une **distribution uniforme**

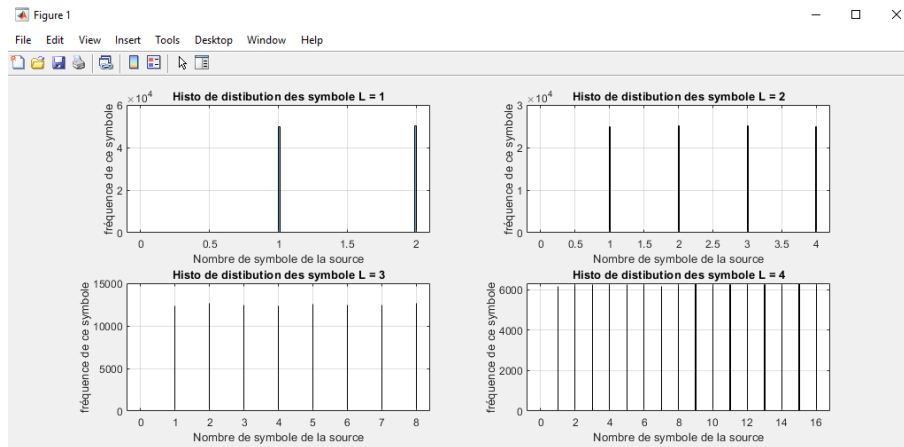


Figure 1: Histogramme Pour différentes valeur de Longueur

3 Mesure d'Entropie :

3.1 Le contenu de P :

Le vecteur P contient la **probabilité de l'émission** de chaque symbole.

3.2 La quantité d'information I et l'entropie H :

Voir le fichier Matlab.

3.3 Utilisation de Logarithme Base 2 :

On utilise la **base 2** pour le calcul de logarithme, parce qu'on cherche le **nombre des bits** (qui est à la **base binaire 2**) dans un message.

3.4 Les valeurs de H pour différente valeurs de L :

$L = 1$, $H(X) = 1.000000$ bits/message

$L = 2$, $H(X) = 1.999955$ bits/message

$L = 3$, $H(X) = 2.999965$ bits/message

$L = 4$, $H(X) = 3.999911$ bits/message

4 Programmation d'une Source :

4.1 Comparaison P et P_z :

Le vecteur de probabilités P est presque **identique** au vecteur de probabilités P_z .

4.2 Source générés :

Une **source Uniforme** (Gaussienne)

4.3 Comparaison entre les deux Sources x et z :

Pour $L = 3$:

$$H(X) = 2.999965 \text{ bits/message}$$

$$H_z(X) = 2.061676 \text{ bits/message}$$

On en déduit qu'avec la même source, on a réduit l'entropie de 3 à 2.062 bits/message cela revient à la **distribution normale des probabilités**.

5 Codage et Compression:

5.1 Commentaires :

Voir le code Matlab

5.2 Les Symboles et leur Codes :

| Symbole | Code | Longueur du Code | Probabilité P_i |
|---------|---------|------------------|-------------------|
| 3 | 1 | 1 | 0.4713 |
| 2 | 01 | 2 | 0.2539 |
| 4 | 001 | 3 | 0.1250 |
| 1 | 0001 | 4 | 0.0624 |
| 5 | 00000 | 5 | 0.060 |
| 6 | 000010 | 6 | 0.0156 |
| 0 | 0000110 | 7 | 0.0078 |
| 7 | 0000111 | 7 | 0.0039 |

$$LMoyz = \sum_{i=1}^8 p_i \cdot n_i = 2.07960$$

5.3 Le degré de compression :

$$\frac{H(Z)}{LMoyz} = 0.99$$

5.4 L'arborescencce de Huffman :

Voir Figure 2 :

5.5 La longueur Moyenne du mot-code :

Pour la source z, la longueur moyenne du mot code après le codage Huffman est **LMoyz=3 bits/message**. (Ainsi que pour la source x)




Figure 2:

5.6 L'intérêt de ce type de codage :

Pour une source **équi-répartie**, il n'y a **pas un intérêt** d'utiliser ce type de codage puisque on trouvera la **même longueur moyenne** si on utilise un codage de **longueur fixe**.